INFORME DE EVIDENCIAS

Mini-proyecto de Machine Learning

Predicción del rendimiento académico en matemáticas

Integrantes

Jhossuant Cabezas
Karen Sanchez

Asignatura: Machine Learning
Fecha: 8 de noviembre de 2026
Rama de integración: develop

Repositorio del proyecto
https://github.com/Jhossuant0520/proyectoFinal_rendimientoEstudiantes

Documento complementario del repositorio. Resume el problema, la implementación, la evaluación, los riesgos, las consideraciones éticas y la evidencia de colaboración.

1. Resumen ejecutivo

El proyecto implementa un prototipo académico de clasificación binaria supervisada para estimar si un estudiante aprueba o no matemáticas. Se utiliza el archivo student-mat.csv del conjunto Student Performance de UCI y se comparan un clasificador de referencia (DummyClassifier), una regresión logística convencional y una regresión logística con ponderación de clases.

La variable objetivo aprueba se define como 1 cuando G3 es mayor o igual a 10 y 0 cuando G3 es inferior a 10. Se excluyen G1 y G2 para estudiar un escenario de predicción que no dependa de las calificaciones parciales. El modelo balanceado se selecciona como artefacto final porque aumenta el Recall de la clase 'no aprueba' de 34,6 % a 46,2 %, aunque reduce el Accuracy global a 55,7 %.

El resultado es experimental y limitado. Ninguna configuración supera al clasificador de referencia en Accuracy; el modelo seleccionado tampoco ofrece precisión suficiente para decisiones académicas autónomas. El análisis por subgrupos detecta diferencias que requieren revisión con más datos.

Ficha del proyecto

Elemento	Descripción
Problema	Clasificación binaria del resultado de matemáticas: aprueba / no aprueba.
Modelo final	Regresión logística con class_weight='balanced'.
Dataset	student-mat.csv: 395 registros y 33 variables originales.
Entradas	Características personales, familiares, escolares y sociales; G1, G2 y G3 se excluyen.
Salida	Clase 1 (aprueba) o clase 0 (no aprueba), además de probabilidad estimada de aprobar.
Uso previsto	Experimento académico y posible señal complementaria para acompañamiento, siempre con criterio humano.
Fuera de alcance	API, interfaz externa, integración institucional, despliegue productivo o decisión automatizada.

Objetivos

- Preparar el conjunto de datos y construir una variable objetivo binaria.
- Entrenar y comparar una línea base y dos configuraciones de regresión logística.
- Evaluar el desempeño con métricas cuantitativas y matrices de confusión.
- Examinar sesgos, equidad, privacidad, impacto social y limitaciones.
- Persistir el modelo y el escalador y comprobar su carga y uso básico mediante pruebas automatizadas.

Alcance y advertencia de uso

El prototipo no diagnostica capacidad, no determina el futuro académico y no debe utilizarse para sancionar, excluir o restringir oportunidades. Una predicción representa una estimación condicionada por los datos de entrenamiento; requiere interpretación y supervisión humana.

2. Datos y preparación

Fuente y procedencia

Se utiliza el subconjunto de matemáticas student-mat.csv del conjunto Student Performance. UCI describe el conjunto original como información de dos escuelas secundarias portuguesas, con variables de calificaciones, demografía, contexto social y escolar. El repositorio advierte que G1 y G2 están fuertemente correlacionadas con G3; excluirlas hace más difícil la predicción, pero plantea un escenario más útil cuando esas notas parciales no están disponibles [1, 2].

Característica	Valor del proyecto
Registros	395 estudiantes
Variables originales	33
Valores faltantes	0 detectados en la exploración
Tipos	16 numéricas y 17 categóricas antes de crear el objetivo, según el análisis del notebook
Calificación final G3	Escala observada de 0 a 20; media aproximada 10,42
Distribución objetivo	265 aprueban (67,1 %) y 130 no aprueban (32,9 %)
Variables codificadas	39 columnas después de pd.get_dummies

Definición de la etiqueta

La etiqueta se deriva de G3: aprueba = 1 cuando G3 ≥ 10 y aprueba = 0 cuando G3 < 10. El umbral de 10 puntos es una decisión adoptada por el equipo para este experimento; debe interpretarse dentro del sistema de calificación representado por el dataset.

Variables predictoras

Se excluyen G3 por definir directamente la etiqueta y G1/G2 para evitar que las notas de los periodos anteriores dominen la predicción. Las características restantes incluyen edad, sexo, zona, educación y ocupación de padres, hábitos de estudio, ausencias, apoyo escolar y familiar, entre otras.

Protocolo ejecutado en el notebook

Etapa	Implementación y evidencia
Carga	Pandas lee data/student-mat.csv con separador punto y coma; forma inicial 395 x 33.
Objetivo	Se crea aprueba a partir de G3; quedan 395 x 34 en el DataFrame.
Selección	X elimina G1, G2, G3 y aprueba; y contiene aprueba.
Codificación	pd.get_dummies(X, drop_first=True, dtype=int); resultado 395 x 39.
División	train_test_split(test_size=0.2, stratify=y, random_state=42): 316 entrenamiento y 79 prueba; proporción de aprobación 0,671 en ambos.
Escalado	StandardScaler.fit_transform(X_train) y transform(X_test). El ajuste del escalador se realiza únicamente con entrenamiento.
Modelado	DummyClassifier y LogisticRegression; una configuración adicional usa class_weight='balanced'.
Persistencia	Joblib guarda modelo_final.joblib y scaler.joblib en models/.

Nota metodológica transparente

En el notebook actual, pd.get_dummies se ejecuta antes de train_test_split. Esta operación no utiliza la variable objetivo, por lo que no es fuga supervisada de la etiqueta; sin embargo, la lista de categorías se determina con todos los registros, incluidos los que después quedan en prueba. Para una separación más estricta del preprocesamiento, se recomienda usar OneHotEncoder dentro de un Pipeline y ajustarlo solo con entrenamiento. En cambio, el StandardScaler sí se ajusta después de la división y exclusivamente sobre X_train.

3. Arquitectura y flujo del sistema

El sistema es un prototipo local de análisis y experimentación. El componente principal es el notebook de Jupyter; no existe una API REST ni una interfaz de usuario externa dentro del alcance implementado.

C4 - Nivel 1: contexto del sistema

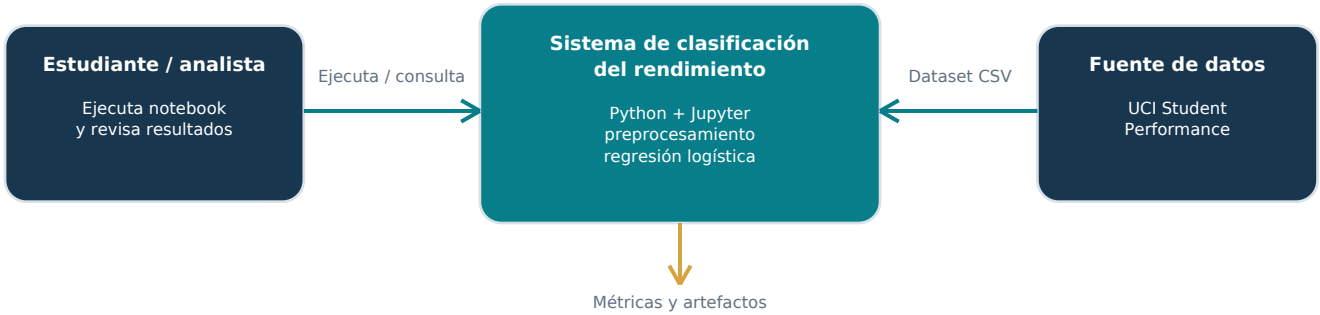


Figura 1. Relación entre el estudiante/analista, el sistema de clasificación y la fuente UCI.

C4 - Nivel 2: contenedores y artefactos

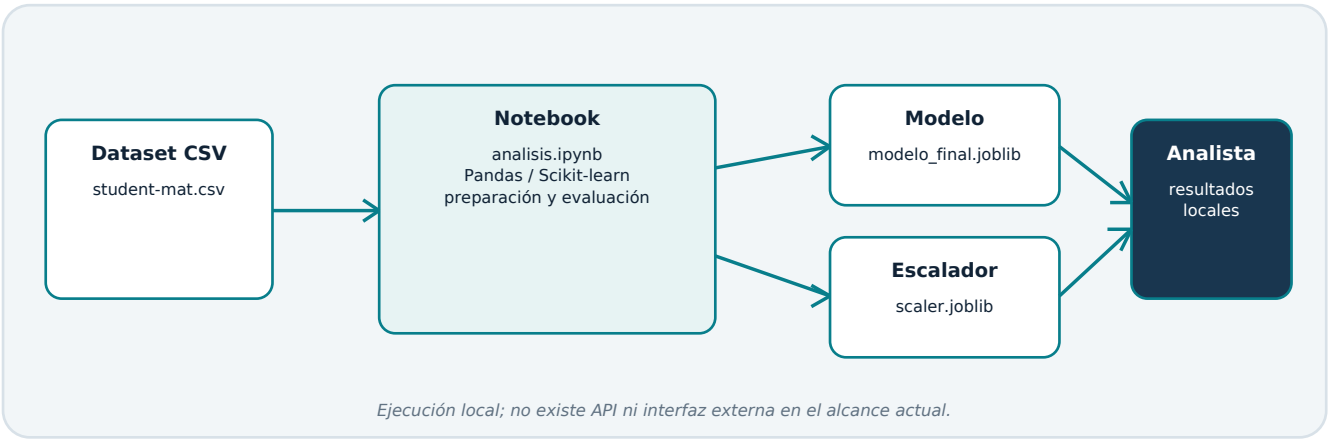
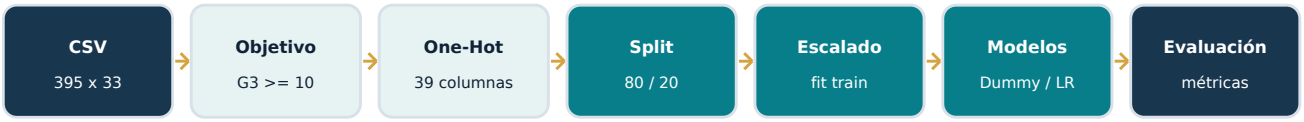


Figura 2. Contenedores lógicos y archivos locales del prototipo.

Flujo de Machine Learning implementado



Nota: One-Hot Encoding se ejecuta antes de la separación en el notebook actual.

Figura 3. Secuencia de carga, codificación, división, escalado, entrenamiento y evaluación. La codificación se ejecuta antes de la división en la versión analizada.

Componentes

Componentes principales: analisis.ipynb coordina el flujo; data/student-mat.csv aporta los registros; models/modelo_final.joblib y models/scaler.joblib conservan el clasificador y el escalador; requirements.txt declara dependencias y tests/test_model_artifacts.py comprueba operaciones básicas sobre los artefactos.

4. Evaluación cuantitativa

La separación fue estratificada (80 %/20 %) y reservó 79 registros para prueba. La clase 1 corresponde a aprueba; la clase 0 corresponde a no aprueba. Para detectar estudiantes que no aprueban, también se reportan Precision, Recall y F1 de la clase 0. Los resultados por clase de esta sección se calcularon a partir de las matrices de confusión del notebook; se expresan con tres decimales.

Comparación de métricas

Modelo	Acc.	P(1)	R(1)	F1(1)	P(0)	R(0)	F1(0)
DummyClassifier	0,671	0,671	1,000	0,803	0,000*	0,000	0,000
Regresión logística	0,633	0,707	0,774	0,739	0,429	0,346	0,383
Regresión logística balanceada	0,557	0,696	0,604	0,646	0,364	0,462	0,407

*P = Precision; R = Recall. Clase 1 = aprueba; clase 0 = no aprueba. *Para DummyClassifier no se predicen casos de clase 0; Precision(0) se fija en 0 con zero_division=0.*

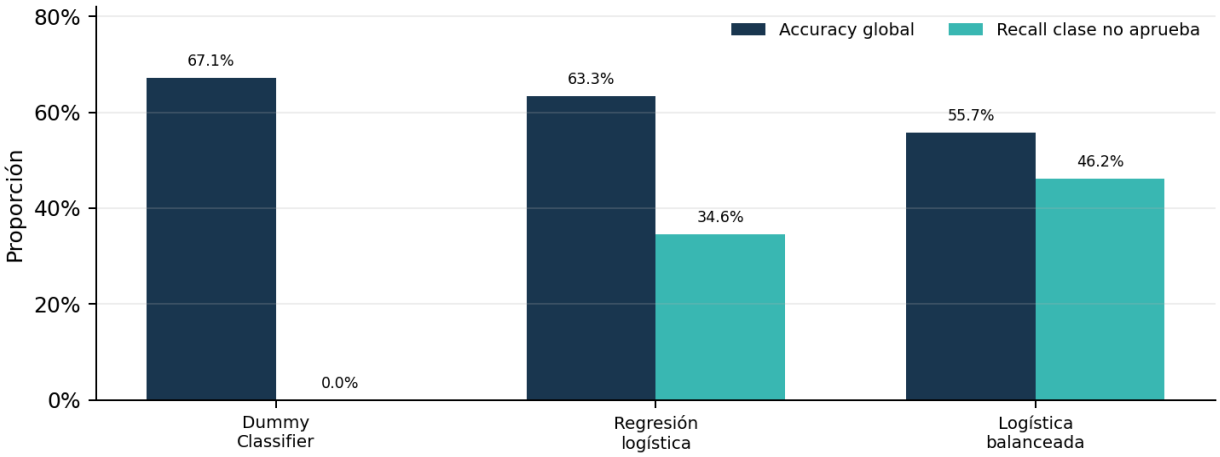


Figura 4. Accuracy global y Recall de la clase no aprueba. La ponderación de clases aumenta la detección de la clase 0, pero reduce la exactitud global.

Interpretación

- DummyClassifier alcanza 67,1 % de Accuracy porque predice todos los registros como aprobados. No identifica a ningún estudiante que no aprueba (Recall de clase 0 = 0).
- La regresión logística convencional logra 63,3 % de Accuracy y detecta 9 de los 26 casos de no aprobación (Recall 34,6 %).
- La versión balanceada detecta 12 de los 26 casos (Recall 46,2 %), pero su Accuracy baja a 55,7 % y su Recall de aprobación baja a 60,4 %.
- Ninguna configuración supera a la línea base en Accuracy. La selección balanceada prioriza la detección de no aprobación, no una mejora general de todas las métricas.

Criterio de selección

Se selecciona la regresión logística balanceada como artefacto final por su mayor Recall para la clase no aprueba. Esta decisión expresa una preferencia por reducir casos de estudiantes no detectados, aceptando más falsas alertas. No significa que el modelo sea suficientemente preciso para uso real.

5. Matrices de confusión y demostración

Las matrices se presentan con filas = clase real y columnas = clase predicha, en el orden [0, 1]. En la lectura estándar, la clase positiva es 1 (aprueba). Para la discusión de riesgo académico, puede tratarse la clase 0 (no aprueba) como evento de interés; por ello se explica explícitamente la convención utilizada.

Matrices observadas

Modelo	Matriz (filas real, columnas predicha)	Exactos	Lectura resumida
DummyClassifier	[[0, 26], [0, 53]]	53/79	Clasifica a todos como aprueba; no encuentra casos de clase 0.
Regresión logística	[[9, 17], [12, 41]]	50/79	Detecta 9 de 26 estudiantes que no aprueban.
Regresión logística balanceada	[[12, 14], [21, 32]]	44/79	Detecta 12 de 26 estudiantes que no aprueban.

Interpretación de la matriz del modelo final

Real / predicción	Predice no aprueba (0)	Predice aprueba (1)
Real no aprueba (0)	12 - detectado correctamente (TP de riesgo)	14 - caso de riesgo no detectado (FN de riesgo)
Real aprueba (1)	21 - falsa alerta (FP de riesgo)	32 - aprobado clasificado correctamente (TN de riesgo)

Si se define 'no aprueba' como la clase positiva de interés para detectar riesgo: TP = 12, FP = 21, FN = 14 y TN = 32. Si se conserva la convención estándar de la etiqueta 1 = aprueba, los mismos cuatro valores se interpretan con la convención opuesta. La definición de clase positiva debe acompañar siempre a la matriz.

Demostración con cinco registros

El notebook toma cinco filas de X_test, genera probabilidades y compara predicción con valor real. Acertó 3 de 5 ejemplos. Estos cinco registros son una demostración tomada del conjunto de prueba, no un conjunto externo de estudiantes nuevos; por su tamaño no permiten estimar desempeño general.

Limitación central

En el modelo balanceado quedan 14 de 26 estudiantes que no aprueban clasificados como aprobados (casos de riesgo no detectados). A su vez, 21 de 53 estudiantes que aprueban se clasifican como no aprobados. Ambos errores tienen consecuencias diferentes y requieren revisión humana.

6. Análisis ético, equidad y privacidad

Procedencia y representatividad

Los registros provienen de dos escuelas secundarias de Portugal. El subconjunto de matemáticas contiene 395 estudiantes. Por su procedencia, antigüedad y tamaño, no representa automáticamente a estudiantes colombianos ni a otros sistemas educativos [1, 2]. La etiqueta 'aprueba' también depende de G3 y del umbral 10/20 definido por el equipo; por tanto, hereda las prácticas de evaluación que originaron esa nota.

Evaluación por subgrupos

El notebook comparó el modelo final por sexo y zona de residencia dentro de los 79 casos de prueba. Los resultados son señales exploratorias y no pruebas concluyentes de discriminación: los grupos tienen tamaños limitados, en especial el grupo rural (n = 13).

Grupo	n	% aprueba real	% predicho aprueba	Accuracy	Recall no aprueba
Mujeres	47	63,8 %	51,1 %	40,4 %	35,3 %
Hombres	32	71,9 %	68,8 %	78,1 %	66,7 %
Zona rural	13	61,5 %	38,5 %	61,5 %	80,0 %
Zona urbana	66	68,2 %	62,1 %	54,5 %	38,1 %

La diferencia de Accuracy entre mujeres (40,4 %) y hombres (78,1 %) es una alerta que debe investigarse. El Recall de no aprobación también difiere: 35,3 % en mujeres y 66,7 % en hombres. No es válido convertir estas diferencias, calculadas en grupos pequeños, en una conclusión causal o en una prueba estadística de discriminación; sí justifican ampliar datos y revisar el impacto de las variables.

Principios de uso responsable

- Equidad: evaluar errores por subgrupos y comprobar que un grupo no soporte de forma desproporcionada falsas alertas o casos de riesgo no detectados.
- Privacidad: minimizar los datos, limitar el acceso, evitar divulgar filas individuales y definir una finalidad legítima para cualquier uso futuro.
- Transparencia: comunicar dataset, variables, umbral, métricas, errores y limitaciones; explicar que la predicción es probabilística.
- Impacto social: evitar etiquetas estigmatizantes y profecías autocumplidas; una alerta debe conducir a acompañamiento, no a sanción.
- Supervisión humana: ninguna decisión sobre un estudiante debe depender exclusivamente del resultado del modelo.

Marco normativo de referencia

Para un eventual tratamiento de datos personales en Colombia debe revisarse la Ley Estatutaria 1581 de 2012 y sus disposiciones aplicables, especialmente principios de finalidad, libertad, calidad y transparencia. Este informe no constituye un concepto jurídico ni certifica cumplimiento normativo [8].

Conclusión ética

Con el desempeño general observado y la brecha exploratoria por sexo, el modelo no es apto para decisiones reales. Su uso debe permanecer académico y experimental, o requerir una nueva validación local, revisión de variables y evaluación de equidad antes de cualquier piloto.

7. Riesgos técnicos y decisiones arquitectónicas

Registro de riesgos

ID	Riesgo	Prob. / impacto	Mitigación
R01	Datos insuficientes o poco representativos.	Alta / Alto	Validar con datos adicionales y documentar alcance de generalización.
R02	Fuga de información entre entrenamiento y prueba.	Media / Alto	Separar datos antes de ajustar transformaciones; usar Pipeline/OneHotEncoder ajustado solo con entrenamiento.
R03	Sobreajuste.	Media / Alto	Validación cruzada, comparación train/test y revisión de regularización.
R04	Sesgos sociodemográficos.	Media / Alto	Evaluar métricas por subgrupos y mantener supervisión humana.
R05	Incompatibilidad de artefactos o dependencias.	Media / Medio	Fijar versiones, documentar entorno y ejecutar pruebas de carga/predicción.

Decisiones de arquitectura (ADR)

ADR	Decisión	Justificación resumida
001	Stack Python, Jupyter, Pandas, NumPy, Scikit-learn, Matplotlib y Joblib.	Proporciona un entorno local sencillo y bibliotecas de análisis y modelado.
002	Regresión logística y DummyClassifier de referencia.	Adecuación a clasificación binaria, simplicidad e interpretación; baseline permite contextualizar métricas.
003	Excluir G1/G2/G3 como predictores y separar conjuntos.	Evita utilizar la variable objetivo o calificaciones parciales que darían una señal dominante para el escenario elegido.
004	CSV para datos y Joblib para modelo/escalador; ejecución local.	Suficiente para el prototipo, sin requerir base de datos, API ni servicio en nube.

Pruebas automatizadas

El archivo tests/test_model_artifacts.py contiene cuatro pruebas: tipo de modelo LogisticRegression, tipo de escalador StandardScaler, capacidad del modelo para generar predicciones y capacidad del escalador para transformar una muestra. En la ejecución registrada en el portátil 2, unittest reportó 4 pruebas OK en aproximadamente 0,18-0,20 segundos.

Se observó una advertencia no fatal: StandardScaler fue ajustado con nombres de características, mientras la prueba de transformación le suministró un arreglo NumPy sin nombres. La prueba pasó; se recomienda alinear el formato de entrada en una mejora futura para evitar la advertencia.

Alcance de las pruebas

Estas pruebas verifican carga, tipo y operación básica de los artefactos. No validan por sí solas la calidad predictiva, la correspondencia exacta del esquema de columnas, el Pipeline completo ni la ausencia de sesgo.

8. Evidencia de desarrollo colaborativo

El repositorio utiliza ramas individuales y una rama de integración. De acuerdo con el historial y la confirmación de los integrantes, se abrieron y fusionaron dos Pull Requests hacia develop: PR #1 (dev_jhossuant → develop) y PR #2 (dev_ksanchez90 → develop). La rama main no se declara como destino de esta integración, porque la actividad solicita consolidar en develop.

Commit	Rama / autor configurado	Aporte
d06a303	dev_jhossuant / Jhossuant Cabezas	Dataset, notebook y modelos de Machine Learning.
eda4e1e	dev_ksanchez90 / Karen Sanchez	requirements.txt y .gitignore.
61d9352	dev_ksanchez90 / Karen Sanchez	Arquitectura C4 y ADR-001 a ADR-003.
67f13ac	dev_ksanchez90 / Karen Sanchez	Corrección del nombre del archivo de arquitectura.
b655bcf	dev_jhossuant / Jhossuant Cabezas	Evaluación del modelo y resultados.
d7bdf79	dev_ksanchez90 / Karen Sanchez	Pruebas automatizadas de artefactos.
404ffd1	dev_ksanchez90 / Karen Sanchez	README ampliado, ADR-004, análisis ético y riesgos técnicos.

Organización final esperada

La rama develop reúne las contribuciones de ambas ramas individuales. El repositorio incluye README, notebook, dataset, modelos, dependencias, pruebas y documentación de arquitectura, evaluación, ética y riesgos. La invitación al docente como colaborador fue enviada por el propietario del repositorio; el estado de aceptación de la invitación debe confirmarse en GitHub.

9. Conclusiones

La actividad permitió construir un flujo básico de clasificación supervisada sobre 395 registros del conjunto Student Performance Mathematics. Se preparó una etiqueta binaria, se excluyeron las calificaciones G1/G2/G3 como predictores, se dividieron los datos de forma estratificada y se entrenaron modelos de referencia y regresión logística.

La regresión logística balanceada mejoró el Recall de la clase no aprueba a 46,2 %, frente a 34,6 % de la versión convencional y 0 % del baseline. Este beneficio se obtiene con una reducción de Accuracy a 55,7 %. Por tanto, el modelo final representa una elección de compromiso enfocada en detectar más casos de no aprobación; no es una solución con desempeño general alto.

El análisis por subgrupos muestra diferencias de rendimiento por sexo y zona de residencia. Dado el tamaño limitado de la muestra y de los grupos, se interpretan como alertas exploratorias. La representatividad geográfica, los datos de menores y el potencial estigmatizante impiden proponer uso autónomo del modelo.

Recomendaciones

- Repetir la codificación con OneHotEncoder dentro de un Pipeline ajustado exclusivamente con el conjunto de entrenamiento.
- Evaluar con validación cruzada y, cuando sea posible, con datos externos de un contexto educativo local.
- Ajustar el umbral de decisión según el costo de falsas alertas y casos de riesgo no detectados; reportar curvas y métricas por clase.
- Ampliar el análisis de equidad con muestras mayores e intervalos de incertidumbre antes de comparar grupos.
- Empaquetar codificador, escalador y clasificador en un único Pipeline persistido, y ampliar pruebas para validar esquema y predicción extremo a extremo.

Conclusión final

El prototipo cumple el propósito académico de mostrar el workflow básico de Machine Learning y una evaluación crítica. Sus métricas y análisis ético indican que debe permanecer como experimento de aprendizaje; cualquier aplicación real exige datos locales, evaluación adicional, protección de datos y supervisión humana.

10. Referencias

[1] UCI Machine Learning Repository. (2008). Student Performance. Dataset 320. https://archive.ics.uci.edu/dataset/320/student+performance. DOI: 10.24432/C5TG7T.

[2] Cortez, P., & Silva, A. M. G. (2008). Using Data Mining to Predict Secondary School Student Performance. Proceedings of the 5th Annual Future Business Technology Conference.

[3] Scikit-learn. Logistic Regression. https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression

[4] Scikit-learn. DummyClassifier. https://scikit-learn.org/stable/modules/generated/sklearn.dummy.DummyClassifier.html

[5] Scikit-learn. Model evaluation: quantifying the quality of predictions. https://scikit-learn.org/stable/modules/model_evaluation.html

[6] Pandas. Documentation. https://pandas.pydata.org/docs/

[7] Joblib. Documentation. https://joblib.readthedocs.io/en/stable/

[8] Colombia. Congreso de la República. Ley Estatutaria 1581 de 2012, por la cual se dictan disposiciones generales para la protección de datos personales. Gestor Normativo de Función Pública: https://www.funcionpublica.gov.co/eva/gestornormativo/norma.php?i=49981

Enlaces de entrega

Recurso	Ubicación
Repositorio GitHub	github.com/Jhossuant0520/proyectoFinal_rendimientoEstudiantes
Rama de integración	develop
Notebook principal	analisis.ipynb
Documentación técnica	docs/ dentro del repositorio

Nota de alcance documental

Este informe resume el estado del prototipo y los resultados observados en el notebook compartido por el equipo. Los resultados numéricos se reproducen a partir de las salidas registradas del experimento. Las métricas adicionales por clase se calcularon a partir de las matrices de confusión reportadas. El informe no certifica despliegue productivo, validez externa, ausencia absoluta de sesgo ni cumplimiento jurídico.

Fin del informe